Examen Analyse de données dans R

John TAGNE

J'ai nommé ma base de données exam, j'ai changé les formats de données appropriées dans Excel puis dans R et j'ai créé un fichier de script séparé pour travailler

Afficher la structure du tableau

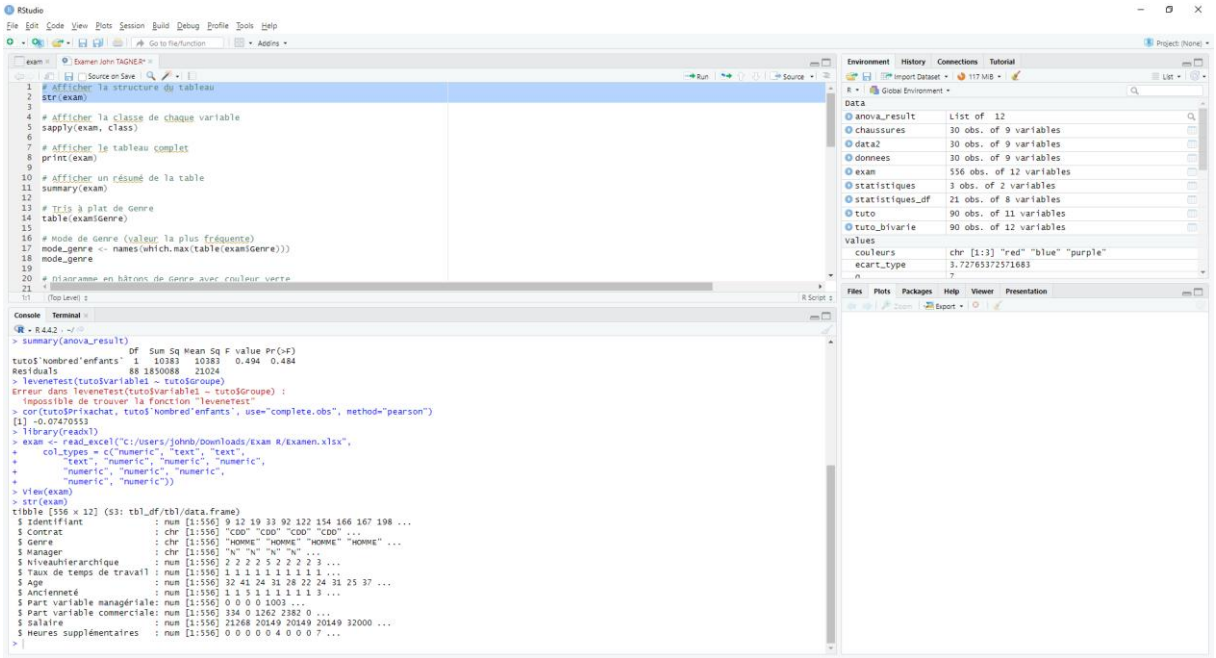

Résumé de la table

```r
# Afficher la structure du tableau
str(exam)

# Afficher la classe de chaque variable
sapply(exam, class)

# Afficher le tableau complet
print(exam)

# Afficher un résumé de la table
summary(exam)

# Tris à plat de Genre
table(exam$Genre)

# Mode de Genre (valeur la plus fréquente)
mode_genre <- names(which.max(table(exam$Genre)))
mode_genre

# Diagramme en bâtons de Genre avec couleur verte
```

```
 $ Niveauhierarchique       : num [1:556] 2 2 2 2 5 2 2 2 2 3 ...
 $ Taux de temps de travail : num [1:556] 1 1 1 1 1 1 1 1 1 1 ...
 $ Age                      : num [1:556] 32 41 24 31 28 22 24 31 25 37 ...
 $ Ancienneté               : num [1:556] 1 1 5 1 1 1 1 1 1 3 ...
 $ Part variable managériale: num [1:556] 0 0 0 0 1003 ...
 $ Part variable commerciale: num [1:556] 334 0 1262 2382 0 ...
 $ Salaire                  : num [1:556] 21268 20149 20149 20149 32000 ...
 $ Heures supplémentaires   : num [1:556] 0 0 0 0 0 4 0 0 0 7 ...
> sapply(exam, class)
             Identifiant                  Contrat                    Genre                  Manager        Niveauhierarchique  Taux de temps de travail
               "numeric"              "character"              "character"              "character"                "numeric"                 "numeric"
                     Age               Ancienneté Part variable managériale Part variable commerciale                 Salaire    Heures supplémentaires
               "numeric"                "numeric"                "numeric"                "numeric"                "numeric"                 "numeric"
> summary(exam)
  Identifiant      Contrat            Genre             Manager          Niveauhierarchique Taux de temps de travail      Age           Ancienneté
 Min.   :  1.0   Length:556         Length:556         Length:556         Min.   :1.0        Min.   :0.0500          Min.   :21.00   Min.   : 1.00
 1st Qu.:146.8   Class :character   Class :character   Class :character   1st Qu.:2.0        1st Qu.:1.0000          1st Qu.:39.00   1st Qu.: 7.75
 Median :288.5   Mode  :character   Mode  :character   Mode  :character   Median :3.0        Median :1.0000          Median :51.00   Median :29.00
 Mean   :287.4                                                           Mean   :3.5        Mean   :0.9289          Mean   :47.42   Mean   :22.67
 3rd Qu.:429.2                                                           3rd Qu.:5.0        3rd Qu.:1.0000          3rd Qu.:57.00   3rd Qu.:36.00
 Max.   :571.0                                                           Max.   :7.0        Max.   :1.0000          Max.   :62.00   Max.   :44.00

 Part variable managériale Part variable commerciale    Salaire       Heures supplémentaires
 Min.   :    0             Min.   :    0.0           Min.   : 20149   Min.   :  0.000
 1st Qu.:    0             1st Qu.:    0.0           1st Qu.: 29235   1st Qu.:  0.000
 Median :    0             Median :    0.0           Median : 33073   Median :  0.000
 Mean   : 1935             Mean   :  980.7           Mean   : 37836   Mean   :  6.481
 3rd Qu.: 3023             3rd Qu.:    0.0           3rd Qu.: 43425   3rd Qu.:  0.000
 Max.   :37899             Max.   :32995.6           Max.   :140735   Max.   :464.750
                                                     NA's   :4
>
```

Description univariée quali sur Genre

```r
# Diagramme en bâtons de Genre avec couleur verte
barplot(table(exam$Genre), col = "green", main = "Répartition du Genre")

# Tris croisés de Genre selon Contrat
table(exam$Genre, exam$Contrat)

# Résumé de Salaire
summary(exam$Salaire)

# Nombre d'observations de Salaire
length(exam$Salaire)

# Calculs des statistiques de Salaire
min(exam$Salaire)
max(exam$Salaire)
quantile(exam$Salaire, probs = c(0.25, 0.5, 0.75))
mean(exam$Salaire)
sd(exam$Salaire)
```

```
> table(exam$Genre)

FEMME HOMME
  204   352
> mode_genre
Erreur : objet 'mode_genre' introuvable
> mode_genre <- names(which.max(table(exam$Genre)))
> mode_genre
[1] "HOMME"
> barplot(table(exam$Genre), col = "green", main = "Répartition du Genre")
> table(exam$Genre, exam$Contrat)

        CDD CDI
  FEMME   5 199
  HOMME  13 339
```

Description univariée quanti sur Salaire

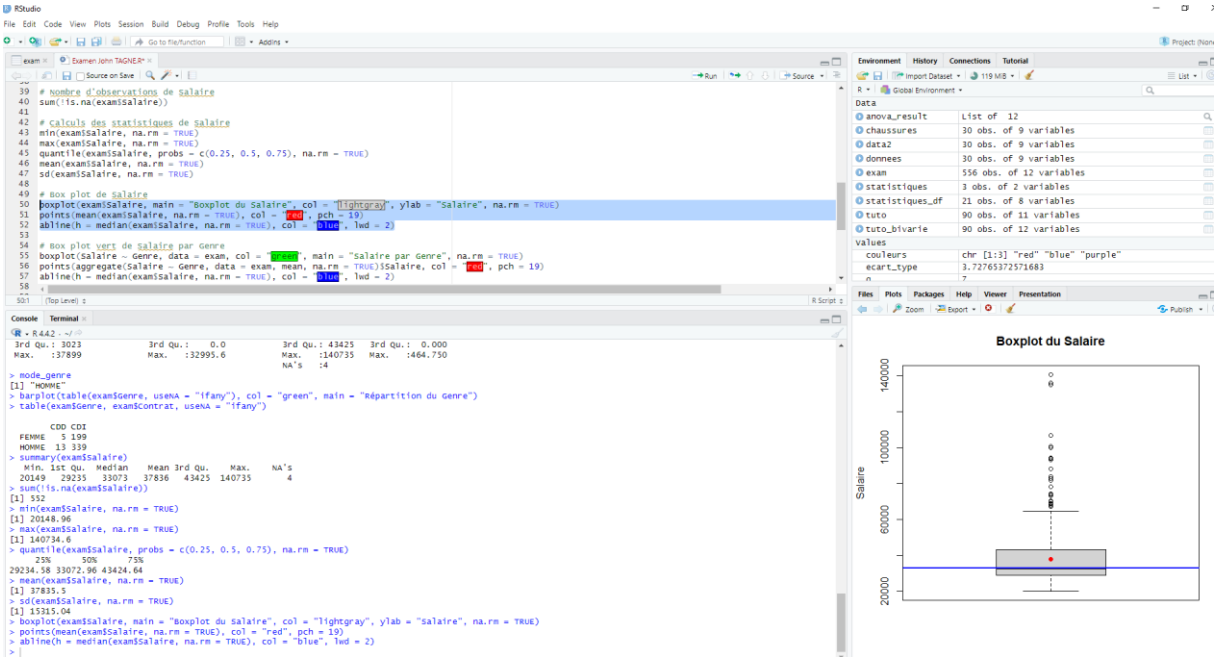

Bivariée quali – quanti : salaire par genre

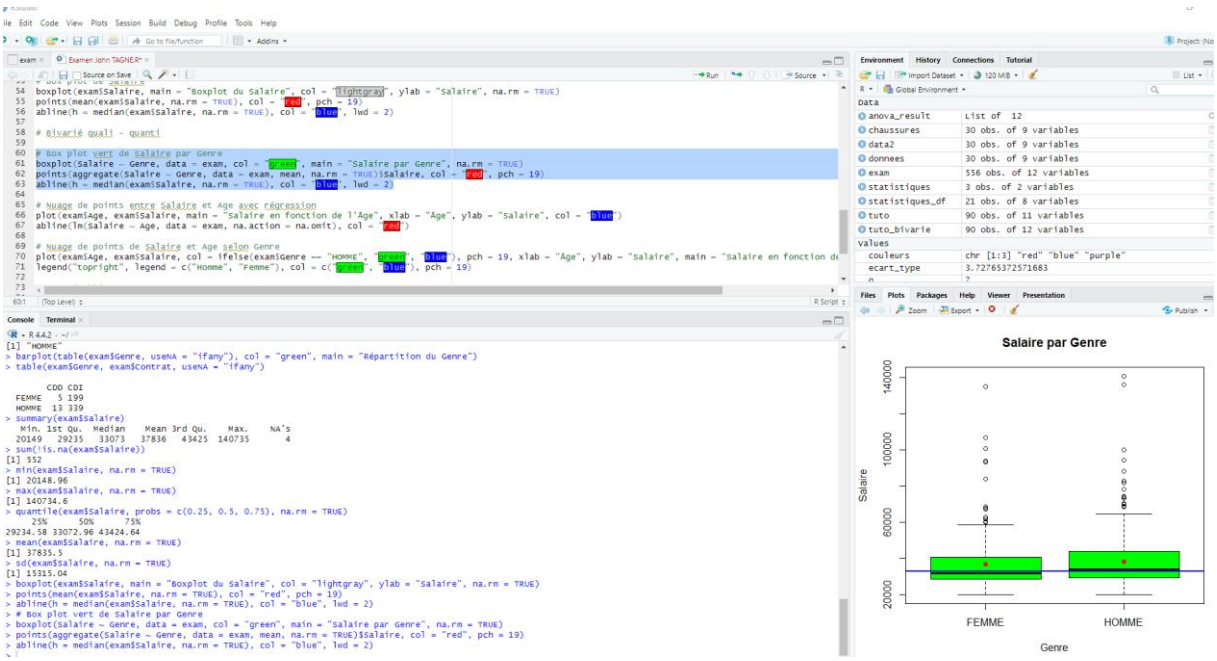

Nuage de points 2 quanti et 1 quali : Salaire selon âge et genre

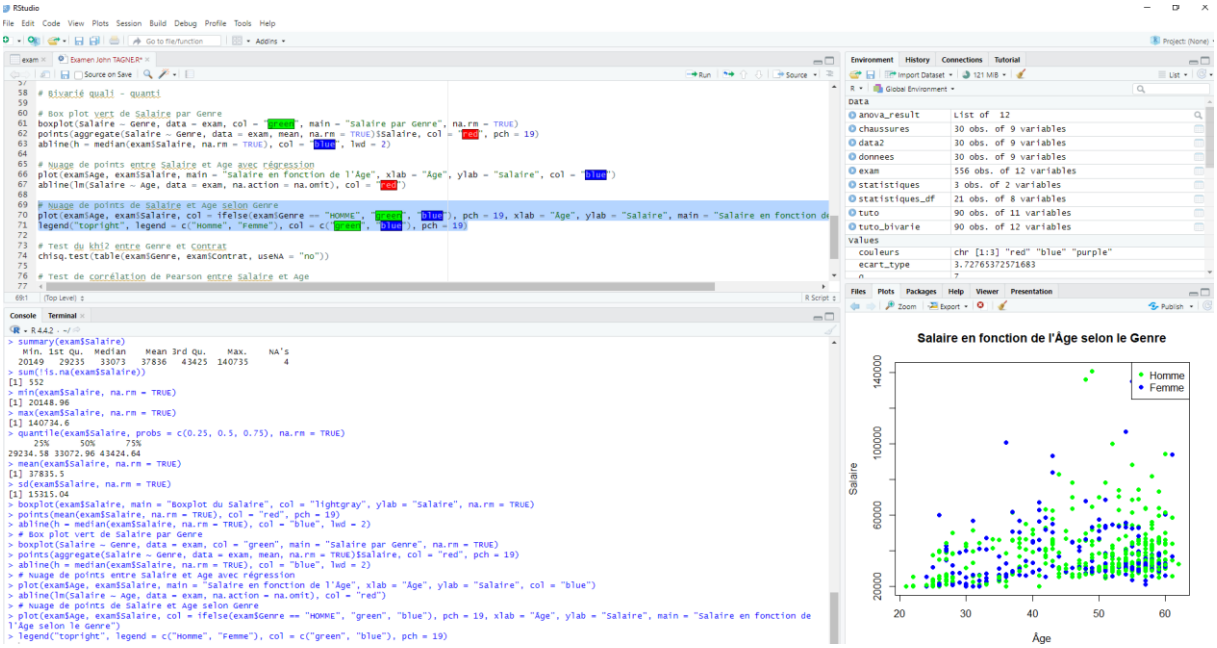

Quelques tests statistiques :

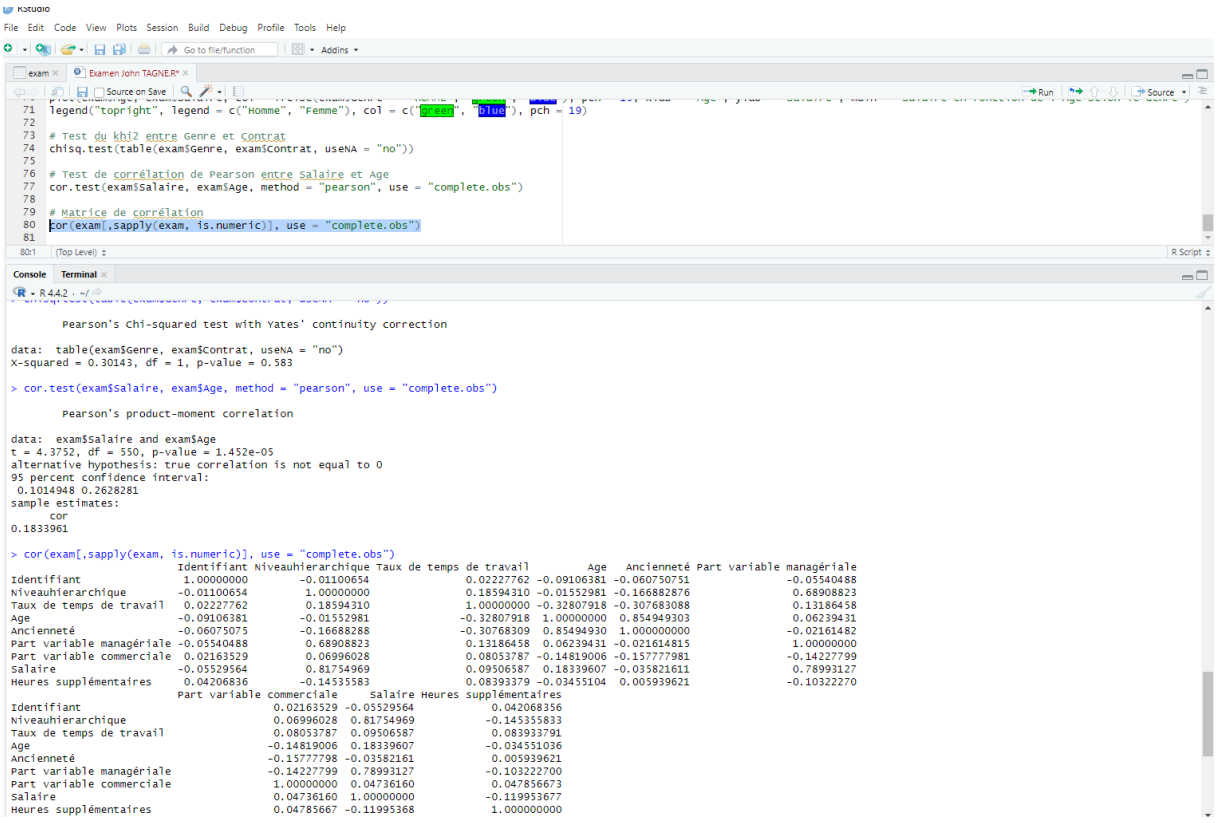

Matrice de corrélation entre Salaire et Age sous forme de tableau

RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

Go to file/function · Addins · Project: (None)

exam | Examen John TAGNE.R*

Source on Save · Run · Source

```r
plot(examiAge, examiSalaire, main = "Salaire en fonction de l'Âge", xlab = "Âge", ylab = "Salaire", col = "blue")
abline(lm(Salaire ~ Age, data = exam, na.action = na.omit), col = "red")

# Nuage de points de Salaire et Age selon Genre
plot(examiAge, examiSalaire, col = ifelse(examiGenre == "HOMME", "green", "blue"), pch = 19, xlab = "Age", ylab = "Salaire", main = "Salaire en fonction de l
legend("topright", legend = c("Homme", "Femme"), col = c("green", "blue"), pch = 19)

# Test du khi2 entre Genre et Contrat
chisq.test(table(examiGenre, examiContrat, useNA = "no"))

# Test de corrélation de Pearson entre Salaire et Age
cor.test(examiSalaire, examiAge, method = "pearson", use = "complete.obs")

# Matrice de corrélation entre salaire et Age affichée sous forme de tableau graphique
cor_matrix <- cor(exam[, c("Salaire", "Age")], use = "complete.obs")
image(1:2, 1:2, cor_matrix, col = heat.colors(12), axes = FALSE, main = "Matrice de corrélation Salaire - Age")
axis(1, at = 1:2, labels = colnames(cor_matrix))
axis(2, at = 1:2, labels = colnames(cor_matrix), las = 2)
text(expand.grid(1:2, 1:2), labels = round(cor_matrix, 2), col = "black")

# Matrice de corrélation de toute la table
cor(exam[,sapply(exam, is.numeric)], use = "complete.obs")
```

80:1 (Top Level) ÷ R Script ÷

Console | Terminal

R 4.4.2 · ~/

```
 Impossible de trouver la fonction "corrplot"
> cor(exam[,sapply(exam, is.numeric)], use = "complete.obs")
                        Identifiant Niveauhierarchique Taux de temps de travail         Age   Ancienneté Part variable managériale
Identifiant              1.00000000         -0.01100654                0.02227762 -0.09106381 -0.060750751                -0.05540488
Niveauhierarchique      -0.01100654          1.00000000                0.18594310 -0.01552981 -0.166882876                 0.68908823
Taux de temps de travail  0.02227762          0.18594310                1.00000000 -0.32807918 -0.307683088                 0.13186458
Age                     -0.09106381         -0.01552981               -0.32807918  1.00000000  0.854949303                 0.06239431
Ancienneté              -0.060750751        -0.16688288               -0.30768309  0.85494930  1.000000000                -0.02161482
Part variable managériale -0.05540488        0.68908823                0.13186458  0.06239431 -0.021614815                 1.00000000
Part variable commerciale  0.02163529        0.06996028                0.08053787 -0.14819006 -0.157777981                -0.14227799
Salaire                 -0.01529564          0.81754969                0.09506587  0.18339607 -0.035821611                 0.78993127
Heures supplémentaires   0.04206836         -0.14535583                0.08393379 -0.03455104  0.005939621                -0.10322270
                        Part variable commerciale     Salaire Heures supplémentaires
Identifiant                          0.02163529 -0.05529564            0.042068356
Niveauhierarchique                   0.06996028  0.81754969           -0.145355833
Taux de temps de travail             0.08053787  0.09506587            0.083933791
Age                                 -0.14819006  0.18339607           -0.034551036
Ancienneté                          -0.15777798 -0.03582161            0.005939621
Part variable managériale           -0.14227799  0.78993127           -0.103222700
Part variable commerciale            1.00000000  0.04736160            0.047856673
Salaire                              0.04736160  1.00000000           -0.119953677
Heures supplémentaires               0.04785667 -0.11995368            1.000000000
> cor_matrix <- cor(exam[, c("Salaire", "Age")], use = "complete.obs")
> image(1:2, 1:2, cor_matrix, col = heat.colors(12), axes = FALSE, main = "Matrice de corrélation Salaire - Age")
> axis(1, at = 1:2, labels = colnames(cor_matrix))
> axis(2, at = 1:2, labels = colnames(cor_matrix), las = 2)
```

Environment | History | Connections | Tutorial

Import Dataset · 116 MiB · List

R · Global Environment

Data

anova_result	List of 12
chaussures	30 obs. of 9 variables
cor_matrix	num [1:2, 1:2] 1 0.183 0.183 1
data2	30 obs. of 9 variables
donnees	30 obs. of 9 variables
exam	556 obs. of 12 variables
statistiques	3 obs. of 2 variables
statistiques_df	21 obs. of 8 variables
tuto	90 obs. of 11 variables
tuto_bivarie	90 obs. of 12 variables

Values

couleurs	chr [1:3] "red" "blue" "purple"
ecart_type	3.737653225251683

Files | Plots | Packages | Help | Viewer | Presentation
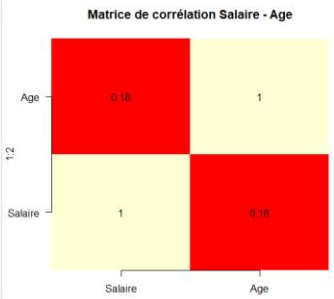
Zoom · Export · Publish